

Agrupación de puestos

Metodología y resultados medidos

Pablo Andrés Encalada

ActuaLab

22 de septiembre de 2026

Contenido

- 1 El problema de agrupación
- 2 Consolidación de grafías
- 3 Estimación dentro y fuera de la celda
- 4 Los otros dos ejes
- 5 Medición

Qué se decide al agrupar


- La referencia de mercado es una mediana sobre las empresas de una celda de cargo.
- La celda la define el agrupamiento de títulos: qué títulos se consideran el mismo puesto.
- La etiqueta de cargo es texto libre escrito por el cliente. No hay taxonomía de referencia, y construir una obligaría a mapear a mano.
- Lo que sigue son las reglas de agrupamiento y lo que se midió de cada una.

Distribución del catálogo de cargos

- 65.181 títulos distintos, con mediana de 2 personas y **1 empresa** por título.
- El 78 % de los títulos tiene una sola empresa detrás y cubre el 21 % de las personas.
- El 1 % de los títulos con 30 o más empresas cubre el 46 %.

En la cola, la mediana de la celda se calcula sobre una sola empresa. Por eso el diseño toma fuerza prestada de las celdas vecinas.

Espesor del catálogo de cargos



Estudios actuariales de nómina, Ecuador 2024–2025, cruzados con el registro de la Superintendencia de Compañías.


Varianza del sueldo y margen recuperable

Con $y = \log(\text{sueldo}/\text{SBU})$, dentro de cada celda de cargo c :

$$y_{fi} = \mu_c + u_f + e_{fi}, \quad u_f \sim (0, \tau^2), \quad e_{fi} \sim (0, \sigma^2).$$

- Medido: $\tau = 0,2917$ entre empresas y $\sigma = 0,1423$ dentro de la nómina. El empleador explica el **81 %** de la varianza residual.
- Comparando la desviación del error real contra ese sueldo irreducible, el margen recuperable por agrupar mejor es del **12,1 %**.
- Los resultados se reportan contra ese 12,1 %, no contra cero.

Descomposición del error de predicción



En color, la fracción del error atribuible al agrupamiento. El resto lo genera el empleador.

Tres pasadas

De 65.181 títulos a **50.420** puestos. Separadas y en este orden, para poder medir cada una por su cuenta:

- 1 **Semántica.** Grafo de similitud del *embedding* con umbral 0,95, agrupado por **enlace completo**: dos grupos se unen si todos los pares entre ellos superan el umbral.
- 2 **Ortográfica.** Distancia de edición 1, contando el intercambio de dos letras contiguas como un solo error. Los pares se buscan por variantes de borrado, que reducen 2.100 millones de comparaciones a 1,8 millones de claves. La absorción es **unidireccional** —el grupo raro, ≤ 2 empresas, entra en el común, ≥ 10 — y se repite cinco veces, para alcanzar la errata de una errata.
- 3 **Flexión de género**, conservando la brecha medida antes de unir.

Restricción común a las tres

El sueldo no interviene en el agrupamiento. Los grupos se construyen y se congelan antes de calcular ninguna referencia.

Por qué enlace completo, y por qué dos criterios

Enlace completo y no simple

Con enlace simple, una cadena de uniones individualmente por encima del umbral conecta extremos que no se parecen. Medido: una componente de **1.758** títulos que incluye ASISTENTE CONTABLE y AUXILIAR DE LIMPIEZA.

Dos criterios y no uno

El *embedding* no separa una errata de una letra:

$s(\text{VENDEROR}, \text{VENDEDOR}) = \mathbf{0,7177}$, frente al umbral de 0,95. La distancia de edición no reconoce sinónimos, como ODONTOLOGA y DENTISTA. Cada criterio cubre lo que el otro no alcanza.

El voto de la empresa f es la mediana de sus n_f personas. La referencia es el cuantil ponderado al 50 % de los votos, con

$$w_f = \frac{1}{\tau_c^2 + \sigma_c^2/n_f}.$$

- Regímenes límite: con n_f grande, $w_f \rightarrow 1/\tau_c^2$, un voto por empresa; con τ_c pequeño, $w_f \rightarrow n_f/\sigma_c^2$, un voto por persona.
- El ratio entre pesos está acotado por $1 + \sigma_c^2/\tau_c^2 \approx 1,24$, con independencia del tamaño de las empresas. No hace falta truncar el voto de las grandes ni descartar el de las pequeñas.

Fuera de la celda: cada vecino, una medición con error

Para un título que no está en la base se combinan los puestos vecinos. El peso sale de cuánto se puede errar usando ese vecino como respuesta:

$$\text{var}_j = \underbrace{1/W_j}_{\text{error de medición}} + \underbrace{\lambda(1 - s_j)}_{\text{sesgo por no ser el mismo puesto}}, \quad w_j = 1/\text{var}_j.$$

- Los dos términos hacen falta: estar bien medido y ser el puesto correcto son cosas distintas. Un vecino distante **se descuenta aunque su celda esté perfectamente medida**.
- Si todos están distantes, el segundo término domina, el intervalo se ensancha y la confianza baja sin ninguna regla adicional.


Estimación de λ

Por momentos: $(m_i - m_j)^2 - (1/W_i + 1/W_j)$ descuenta el ruido de medición conocido de ambas celdas, y el residuo se ajusta contra $1 - s_j$ por el origen. Se estima **por escalón jerárquico**, donde varía un factor 18.

Segundo eje: nivel jerárquico

- El escalón explica $\omega^2 = 0,2462$ de la varianza de nivel dentro de las etiquetas anchas.
- Recorrido salarial de $2,11\times$ entre el escalón más bajo —ayudante, auxiliar, operario— y el más alto —gerente, director.
- Se estima **dentro de empresa y área**, de modo que no incorpora el efecto empleador ni la composición sectorial.
- El escalón se deriva de la propia etiqueta por palabra de rango, y bloquea las uniones entre niveles distintos en la pasada semántica.

La escalera de niveles




Salario relativo al escalón más bajo, estimado dentro de empresa y área.

Tercer ajuste: tamaño de empresa

- Segmentar el mercado por tamaño **no** estrecha la banda: la incertidumbre del centro sube más de lo que baja el ancho.
- El centro sí está sesgado, y el sesgo crece con el escalón. El tamaño entra como **desplazamiento de la banda completa**, sin reestimarla.
- El ajuste se aplica por escalón y no cargo a cargo: en la selección automática cargo a cargo, el placebo seleccionó más cargos que la señal real.

Sesgo de nivel por tamaño de empresa



A una empresa pequeña se le indicaba que su gerente general cobra un 56 % por debajo del mercado. Entre empresas de su tamaño, estaba por encima de la referencia.

Cómo se puntúa un cambio

Una banda no se puntúa como un número: no hay un valor con el que compararla.

- La pérdida *pinball* cobra distinto según el lado. Para el percentil 25, **pasarse cuesta el triple** que quedarse corto.
- Eso la hace una regla **propia**: se minimiza diciendo la verdad, así que no se puede ganar ensanchando la banda. Con $q = 0,5$ es el error absoluto.
- Se puntúa en $q = 0,25$ y $q = 0,75$ sobre la banda de empresas, y se reporta la media.

Las dos variantes se construyen sobre **el mismo remuestreo**, así que la diferencia no arrastra el ruido de la muestra. El intervalo sale de remuestrear **empresas**, no filas. Y el criterio de adopción se escribe antes de correr.

El placebo de permutación

Toda reagrupación aumenta la cobertura por construcción: al juntar celdas hay más respaldo por celda.

El contraste

Se repite el experimento enviando las mismas fusiones a destinos elegidos **al azar**. Si el placebo mejora igual, la ganancia procede del mecanismo y no de la regla.

Fusión por errata	pinball	IC 95 %
Regla real	-0,00001	[-0,00004, +0,00002]
Placebo	+0,00130	[+0,00081, +0,00180]

La regla real no empeora el error; el placebo lo empeora cien veces más.

Qué ganó cada cambio

Unir solo si *todos* los pares superan el umbral

El efecto pasa de $+0,0154$ a $-0,0030$: **el signo se invierte**. Con la regla de cadena, agrupar empeoraba la referencia.

Consolidar las grafías del mismo puesto

$-0,00001$, con el intervalo sobre cero: **no mejora la precisión**. Lo que mejora es la cobertura, del 57,7 al 64,1 %. Midiendo solo el error, este cambio se habría descartado.

Banda por celda, con cuantiles empíricos

El recorrido de cobertura entre cargos cae de 50,5 a **4,3** puntos: la banda deja de cubrir al 18 % en unos cargos y al 98 % en otros.