

Benchmarking salarial con etiquetas de puesto delgadas

Cuánto error es reducible por elegir mejor el grupo de comparación

Pablo Andrés Encalada

Maestría en Inteligencia Artificial — USFQ

21 de septiembre de 2026

Contenido

El problema

El método

Resultados medidos

La dificultad no está en el cálculo

Un benchmark salarial responde a una pregunta simple: *cuánto paga el mercado por este puesto.*

El cálculo es una mediana. Toda la dificultad está en el **denominador**: qué observaciones entran en ella.

Cómo lo resuelve la industria

Taxonomías duras — catálogos cerrados de puestos a los que el cliente mapea su nómina a mano. Ese mapeo es caro, es lento, y es donde se pierde la información: dos empresas mapean el mismo puesto a categorías distintas según quién haga el ejercicio.

La alternativa es usar la etiqueta que la empresa ya escribió. El problema es que esa etiqueta es **texto libre**.

El catálogo real


Estudios actuariales de nómina ecuatorianos, 2024–2025, cruzados con el registro de la Superintendencia de Compañías.

Títulos distintos	65.181
Mediana de personas por título	2
Mediana de empresas por título	1

El **78 %** de los puestos tiene **una sola empresa** detrás, y entre todos cubren el 21 % de las personas. En el otro extremo, el 1 % con 30 o más empresas cubre el 46 %.

La cola larga no se arregla con más modelo: se arregla tomando fuerza prestada de un vecindario.

El catálogo real



Casi todos los puestos son delgados; casi toda la gente está en los gruesos.

El límite que ningún método por puesto puede cruzar

Antes de proponer nada, cuánto hay que ganar. Descomponiendo la varianza de $y = \log(\text{suelo}/\text{SBU})$ dentro de cada celda de cargo:

$$y_{fi} = \mu_c + u_f + e_{fi}, \quad u_f \sim (0, \tau^2), \quad e_{fi} \sim (0, \sigma^2)$$

con f empresas e i personas dentro de la empresa. Medido sobre el ajuste:

$$\tau = 0,2917 \quad \sigma = 0,1423$$

El efecto empleador es el doble que la dispersión dentro de la nómina: **la empresa explica el 81 % de lo que no se puede predecir desde el puesto**. Dos personas con el mismo cargo en empresas distintas cobran muy diferente, y eso no es ruido de medición.

El techo de mejora es del orden del 12 %


Subconjunto	sd real	sd irreducible	Techo
Todo el ajuste	0,3700	0,3253	12,1 %
Lejos del piso del SBU ($y > 0,05$)	0,4322	0,3750	13,2 %

Cualquier resultado debe leerse contra ese número, **no contra cero**. Un método que reduzca el error un 4 % recupera un tercio de todo lo disponible; uno que prometa un 40 % está midiendo mal.

Contribución

Los trabajos previos comparan métodos entre sí sin establecer contra qué techo compiten. Medir el presupuesto disponible es, en sí mismo, un aporte.

El techo de mejora es del orden del 12 %



La franja en color es todo lo que una agrupación mejor puede recuperar. El resto lo genera el empleador.

Vista general

Se construye una **base de referencia** una vez y se consulta muchas. Dado un título de puesto:

- ▶ si está en la base, se usa la referencia de su propia celda;
- ▶ si es nuevo, se embebe y se coloca entre los puestos que se le parecen.

Lo segundo no es un adorno: el **35,9 %** de las personas de una nómina nueva tiene un título que no está en la base. Sin la rama de analogía, la cobertura se queda en dos tercios.

El sistema *siempre* responde. Como se responde siempre, la marca de confianza deja de ser decorativa: es lo único que separa “esto lo sé” de “esto lo estoy suponiendo”.

El estimador: pesos inverso-varianza

El voto de cada empresa f en una celda es la mediana de sus personas, m_f , ponderada por

$$w_f = \frac{1}{\tau^2 + \sigma^2/n_f}$$

La referencia es el cuantil ponderado al 50 % de los votos con esos pesos. Del modelo sale todo, **sin hiperparámetros**.

Régimen	w_f tiende a	Equivale a
$n_f \rightarrow \infty$	$1/\tau^2$, igual para todas	una empresa, un voto
$\tau^2 \rightarrow 0$	n_f/σ^2	una persona, un voto

Los dos regímenes límite son las dos posturas del debate de diseño, y el peso las interpola con los datos en vez de zanjarlo por criterio.

Una empresa grande no puede dominar la celda

$$\frac{w_{\text{máx}}}{w_{\text{mín}}} \leq 1 + \frac{\sigma^2}{\tau^2} \approx 1,24$$

El ratio máximo entre pesos está acotado por la **razón de varianzas**, no por el tamaño relativo de las empresas.

Una empresa de 3.000 personas no puede dominar la celda — y no hace falta descartar el voto de las pequeñas para conseguirlo.

Esta estructura ancla el trabajo en **estimación en áreas pequeñas** —tomar fuerza prestada de un vecindario— y no en la búsqueda de una variable que faltaba.

El vecindario: por qué no se pesa por similitud

La versión ingenua pesa cada vecino por *similitud* $\times$ *precisión*.
Medido sobre un caso real:

Vecino de OPERADOR DE PARQUEADERO	Similitud	Peso ingenuo
OPERADOR DE PARQUEADEROS	0,989	8 %
OPERADOR DE EXCAVADORA	0,825	46 %

El sistema tenía la respuesta exacta delante y le hizo caso a una excavadora, porque la excavadora tenía más datos.

Cada vecino, una observación ruidosa

$$\text{var}_j = \underbrace{1/W_j}_{\text{error de medición}} + \underbrace{\lambda(1 - s_j)}_{\text{castigo por no ser el mismo puesto}}$$

y se pesa por $1/\text{var}_j$. Un vecino lejano se descuenta aunque esté perfectamente medido.

λ **se estima de los datos, no se elige**: es cuánto difieren de verdad dos celdas por unidad de distancia semántica. Se estima por escalón jerárquico, porque varía un factor 18 entre ellos.

El caso degenerado se resuelve solo

Para LOTERO el embedding no encuentra nada parecido y se agarra a la terminación *-ero*: LINIERO, BOTERO, TESORERO. Si todos los vecinos están lejos, $\lambda(1 - s_j)$ domina, el intervalo se dispara y la confianza cae a BAJA sin programar ninguna excepción.

Consolidación de grafías

Tres pasadas, en orden y por separado para que cada una sea auditable:

1. **Semántica**, por *enlace completo* sobre el grafo de similitud, umbral 0,95. El enlace simple percola: produce un grupo de 1.758 títulos que contiene a la vez ASISTENTE CONTABLE y AUXILIAR DE LIMPIEZA, unidos por una cadena de saltos individualmente razonables.
2. **Por errata**, con indexado por variantes de borrado. Absorbe el grupo raro dentro del común exigiendo asimetría.
3. **Por grafía de género**, conservando y reportando la diferencia que había antes de unir.

Cobertura directa: del **57,7 % al 64,1 %**, sin costar precisión.

Hallazgo lateral: **el embedding no reconoce una errata de una letra**. VENDEROR contra VENDEDOR puntúa 0,7177, frente a un umbral de 0,95.

La banda


El entregable no es un número sino un intervalo, y responde a *qué paga la mitad central de las empresas*. De ahí dos decisiones:

- ▶ **σ no entra en la banda de empresas.** El nivel de una empresa es $\mu_c + u_f$, con varianza τ_c^2 ; σ^2 separa a dos personas de la misma nómina y no mueve el nivel del empleador.
- ▶ **Con datos de sobra se usan los cuantiles empíricos** de los votos, no una normal. Describen la forma real, que va de un pico a una cola larga según el cargo.

Se entregan dos bandas: la de *empresas*, para política salarial, y la de *personas* —que sí lleva σ — para situar a un individuo.

Corrección por tamaño de empresa

Segmentar por tamaño **no** estrecha la banda: la incertidumbre del centro sube más de lo que baja el ancho. Pero el tamaño sí corrige un **sesgo grande en el centro** de los cargos altos: el rango de error pasa de $-56,0\%$ / $+81,9\%$ a $-12,1\%$ / $+17,9\%$.



Segmentar para estrechar y segmentar para corregir el centro son dos preguntas distintas, y la respuesta no es la misma.

Protocolo de medición

El instrumento se construyó **antes** que el modelo: una regla de medición torcida no se detecta midiendo, se detecta auditándola antes de usarla.

- ▶ **Partición por empresa, nunca por fila.** Con partición aleatoria la empresa de test aparece en train y se acierta por la razón equivocada.
- ▶ **Todo intervalo se remuestrea por empresa.** La fila no es la unidad independiente.
- ▶ **Puntuación propia.** Pérdida *pinball* en $q = 0,25$ y $q = 0,75$ sobre la banda de empresas: se minimiza diciendo la verdad.
- ▶ **Criterio escrito antes de mirar.** Cada experimento declara qué resultado lo adoptaría y cuál lo rechazaría, antes de correr.
- ▶ **Placebo en todo cambio de agrupación.**
- ▶ **El 20 % de test no se toca** hasta congelar el pre-registro.

Por qué el placebo es la pieza que decide

Cualquier reagrupación mejora la cobertura *por construcción*. El placebo —mismos grupos, destinos barajados— es lo único que distingue señal de mecánica.

Tres ejemplos de la misma serie:

- ▶ D-025: el placebo *no* tuvo potencia. La decisión se registró como “no validada, solo no contradicha”.
- ▶ D-031: el placebo sí discriminó. Mandar las mismas absorciones a destinos al azar cuesta +0,00130 de pinball frente a −0,00001 de la regla real — cien veces más.
- ▶ D-018: el placebo **eligió más cargos que la selección real** (118 contra 93). Bastó para descartar el método.

El resultado negativo del centro

El proyecto arrancó sobre la hipótesis de que la **composición del pago** (fijo, comisiones, extras) discrimina puestos.

Medido


R^2 fuera de muestra = +0,0042, contra un placebo en -0,0002.

Vale un **0,21 %** sobre un techo del 12 %. Se descartó.

El eje que sí paga resultó ser el **nivel jerárquico**: $\omega^2 = 0,2462$, con un recorrido salarial de $2,11\times$ entre el escalón más bajo y el más alto.

El protocolo detectó que la premisa propia del proyecto era falsa. Ese giro, y el instrumento que lo hizo visible, son parte del aporte.

El eje que sí paga



Recorrido de 2,11x entre el escalón más bajo y el más alto.

Lo que se midió y no entró

Hipótesis	Resultado	Ref.
La composición del pago discrimina puestos	$R^2 = +0,0042$ contra placebo $-0,0002$	D-013
El sector estrecha la banda	pinball 0,1289 contra 0,1255 sin segmentar. Empeora	D-022
El sector corrige el centro	No se sostiene fuera de muestra. Se retira lo adoptado	D-022
La escalera debe estimarse con medianas	La mediana pierde: $+0,00069$, IC sobre cero	D-024
Comparar contra el sector específico del cliente	Peor cuanto más fino. La sección acierta un 9,2 % más	D-029
Dar contexto al embedding mejora la representación	Mejora el vecindario y <i>no</i> mueve las bandas: el IC cruza el cero	D-030

Un catálogo de resultados negativos no es un apéndice: impide suponer que lo obvio no se probó.

El caso del sector: adoptado y luego retirado

Es el único eje que entró al modelo y después salió.

- ▶ D-014 lo adoptó: $-13,2\%$ de desviación dentro de las etiquetas anchas, placebo en $0,9\%$. Con la condición de medirlo fuera de muestra.
- ▶ D-022: no se sostuvo, ni para la banda ni para el centro. Se retiró.

La razón apareció después, al descomponer la varianza: de la diferencia de pago *entre empresas* por un mismo cargo, la división CIIU explica **6 puntos netos** (0,389 en crudo contra 0,325 barajando). Casi todo era inflación mecánica de partir en grupos pequeños.

Lo que una empresa paga por un contador depende de la empresa, no de si vende libros o repuestos.

Cobertura y estado del sistema

Cobertura	
Techo de la etiqueta cruda	66,6 %
Directa, sin consolidar	57,7 %
Directa, consolidada	64,1 %
Títulos desconocidos	35,9 %

El artefacto	
Títulos en la base	65.181
Puestos tras consolidar	50.420
Empresas con datos	6.722
Resolubles por RUC	221.754
Decisiones con evidencia	31
Pruebas automatizadas	381

La rama de analogía convierte un sistema que cubre dos tercios en uno que responde siempre. El coste de responder siempre se paga en la marca de confianza, no en silencio.

Límites de lo reportado

- ▶ **El techo es el techo.** El empleador explica el 81 % de lo que no se puede predecir desde el puesto. Este trabajo entrega el *mercado*, no la política salarial de una empresa concreta.
- ▶ **El conjunto de test sigue sin tocarse.** Todo lo reportado está medido sobre particiones de validación dentro del ajuste. Es correcto por diseño —el test se toca una vez, después del pre-registro— pero lo que hay es consistencia interna, no validación externa.

La contribución no es el algoritmo: es medir contra qué techo compete.