

# Cómo se agrupan los puestos

La metodología detrás del benchmark, y lo que se midió

Pablo Andrés Encalada

ActuaLab

21 de septiembre de 2026

# Contenido

- 1 Por qué agrupar es el problema
- 2 Consolidar las grafías
- 3 Estimar dentro y fuera de la celda
- 4 Los otros dos ejes
- 5 Cómo se mide

# El estimador es trivial; el denominador no

- La referencia de mercado es una mediana. Eso no tiene dificultad.
- Toda la dificultad está en decidir **qué observaciones entran** en ella: qué títulos de cargo son el mismo puesto.
- Esa decisión es el modelo. Todo lo que sigue son las reglas con las que se toma, y lo que costó medir cada una.

## La restricción de partida


La etiqueta de cargo es texto libre escrito por el cliente. No hay taxonomía a la que apoyarse, y construir una obligaría a mapear a mano, que es justo lo que se quiere evitar.

# El catálogo es demasiado delgado para agrupar por fuerza bruta

- 65.181 títulos distintos, con mediana de 2 personas y **1 empresa** por título.
- El 78 % de los títulos tiene una sola empresa detrás, y entre todos cubren el 21 % de las personas.
- El 1 % de los títulos con 30 o más empresas cubre el 46 %.

Una mediana calculada sobre un título de la cola no es el mercado: es el sueldo de un vecino. La cola larga no se arregla con más modelo, se arregla **tomando fuerza prestada** de un vecindario.

# Espesor del catálogo de cargos



Estudios actuariales de nómina, Ecuador 2024–2025, cruzados con el registro de la Superintendencia de Compañías.


# Cuánto margen hay por agrupar mejor

Con  $y = \log(\text{suelo}/\text{SBU})$ , dentro de cada celda de cargo  $c$ :

$$y_{fi} = \mu_c + u_f + e_{fi}, \quad u_f \sim (0, \tau^2), \quad e_{fi} \sim (0, \sigma^2).$$

- Medido:  $\tau = 0,2917$  entre empresas y  $\sigma = 0,1423$  dentro de la nómina. El empleador explica el **81 %** de la varianza residual.
- Contra ese suelo irreducible, agrupar mejor puede recuperar como mucho un **12,1 %** del error.
- Es la cifra contra la que hay que leer cualquier resultado. Una mejora del 4 % es un tercio de todo lo disponible; una del 40 % está mal medida.

# Descomposición del error de predicción



En color, la fracción del error que una agrupación mejor puede recuperar. El resto lo genera el empleador.

# Tres pasadas, y una regla que las gobierna

De 65.181 títulos a **50.420** puestos, en tres pasadas separadas y en este orden, para que cada una sea auditable y medible por su cuenta:

- 1 **Semántica:** enlace completo sobre el grafo de similitud del *embedding*.
- 2 **Ortográfica:** absorción de erratas por distancia de edición.
- 3 **Flexión de género:** ENFERMERA y ENFERMERO se unen, conservando y reportando la brecha medida *antes* de unirlos.

## La regla que las gobierna

El **suelo nunca entra en la agrupación**. Los grupos se construyen, se congelan, y solo entonces aparece el sueldo para calificarlos. Si la métrica decidiera la granularidad, acabaríamos con bandas salariales disfrazadas de puestos.

# Pasada 1: enlace completo sobre el grafo de similitud

- 1 Cada título es un vector de `text-multilingual-embedding-002`. De cada uno se toman sus **10** vecinos más próximos y se conservan las aristas con coseno  $\geq 0,95$ .
- 2 Las aristas se recorren **de más a menos similares**, uniendo grupos de forma voraz.
- 3 Dos grupos se unen solo si **el par peor entre ellos** aguanta el umbral:  $\min(Z_A Z_B^T) \geq 0,95$ , todos contra todos.

Ese tercer paso es toda la diferencia con un *union-find*, que uniría en cuanto existiese *una* arista.

Además, un **candado de escalón**: dos títulos de nivel jerárquico distinto no se unen aunque el coseno lo permita.

# Por qué el par peor, y no cualquiera

## Con enlace simple basta una cadena

Cada salto es individualmente razonable y el resultado no lo es. Medido: una componente de **1.758** títulos que contiene a la vez ASISTENTE CONTABLE y AUXILIAR DE LIMPIEZA. Ninguna arista de esa cadena es absurda; la componente sí.

Con enlace completo el daño desaparece. Y se ve de dónde venía: una vez puesto el enlace completo, el candado de escalón solo rechaza **18 uniones de 15.870**.

El daño nunca vino de pares malos, sino de **la cadena que los conectaba**.

## Pasada 2: encontrar las erratas sin comparar todo con todo

65.181 títulos son **2.100 millones** de pares. Comparar todos no es una opción.

### Indexado por variantes de borrado

De cada título se generan todas las cadenas con **un carácter menos** y se indexan. Dos cadenas a distancia  $\leq 1$  comparten siempre una de esas variantes, así que basta mirar las que caen en la misma clave: **1,8 millones** de claves, y segundos.

La comprobación final es distancia de edición **exactamente 1**: sustituir, insertar o borrar un carácter —o **intercambiar dos letras contiguas**, que es el dedazo más común al teclear y que Levenshtein contaría como dos errores.

## Pasada 2: cuándo se absorbe, y en qué dirección

- **Lo raro entra en lo común, nunca al revés:** el lado raro con  $\leq 2$  empresas, el común con  $\geq 10$ .
- Por eso **no encadena**: el destino no puede ser absorbido a su vez, porque para serlo tendría que tener  $\leq 2$  empresas y acaba de exigírsele  $\geq 10$ .
- El suelo de longitud —8 letras— se le exige a la grafía **común**, no a la rara. VEDEDOR tiene 7 letras y 2 empresas; su común VENDEDOR tiene 8 y 767. El riesgo de SUB/SUR está en que *las dos* sean cortas y frecuentes, y de eso ya se ocupa el suelo de empresas.
- **Cinco vueltas**, por la errata *de* una errata: VENDEROA viene de VENDERORA, que viene de VENDEDORA. En una sola vuelta ese par se evalúa leyendo el grupo original de VENDERORA, que todavía tiene una empresa, y falla el suelo.

# El caso que lo motivó, y lo que costó

Escribiendo Vendedor en el buscador del front salían VENEDRO, VENDEROA, VEDEDOR y VENEDOR —una empresa cada una— por encima de VENEDOR, que tiene 767.

## Las tres relajaciones, medidas juntas

Transposición, suelo de longitud sobre la común, y cinco vueltas.

Resultado: 592 absorciones contra 528, y +0,021 % de cobertura directa.

No es encadenar a ciegas, que es justo lo que el diseño de una sola vuelta evitaba: el destino sigue exigiendo 10 empresas en cada vuelta. Nunca se pasa por un grupo raro; solo se descubre que un raro estaba a un dedazo de un grupo que ya era grande.

# Por qué hacen falta las dos pasadas, y no una

El *embedding* no distingue una errata de una letra

$s(\text{VENDEROR}, \text{VENDEDOR}) = 0,7177$ , frente al umbral de fusión de 0,95. Las trece grafías de VENDEDOR las une la distancia de edición, no el modelo semántico.

Y la distancia de edición no ve un sinónimo

ODONTOLOGA y DENTISTA no comparten ni una letra en el mismo sitio. Eso solo lo une el *embedding*.

Son dos señales ortogonales. Cada una cubre el punto ciego de la otra, y por eso van en pasadas separadas y no en un único criterio mezclado.

# Dentro de la celda: cada empresa vota según su precisión

El voto de la empresa  $f$  es la mediana de sus  $n_f$  personas; la referencia, el cuantil ponderado al 50 % de los votos, con

$$w_f = \frac{1}{\tau_c^2 + \sigma_c^2/n_f}.$$

- Los dos regímenes límite son las dos posturas del debate clásico: con  $n_f$  grande, un voto por empresa; con  $\tau_c$  pequeño, un voto por persona. El peso interpola con los datos en vez de zanjarlo por criterio.
- El ratio entre pesos lo acota la razón de varianzas,  $w_{\text{máx}}/w_{\text{mín}} \leq 1 + \sigma_c^2/\tau_c^2 \approx 1,24$ : una empresa de 3.000 personas **no puede dominar la celda**, y no hace falta descartar el voto de las pequeñas.

# Fuera de la celda: la similitud no es el peso

Ponderar cada vecino por similitud  $\times$  precisión invierte el orden:

| Vecinos de OPERADOR DE PARQUEADERO | Similitud | Peso |
|------------------------------------|-----------|------|
| OPERADOR DE PARQUEADEROS           | 0,989     | 8 %  |
| OPERADOR DE EXCAVADORA             | 0,825     | 46 % |

Así pesaba la primera versión: tenía la respuesta exacta delante y le hizo caso a una excavadora, porque la excavadora tenía más datos. La formulación que se usa lo corrige tratando cada vecino como una medición con error.

# Cada vecino, una observación ruidosa del puesto objetivo

$$\text{var}_j = \underbrace{1/W_j}_{\text{error de medición}} + \underbrace{\lambda(1 - s_j)}_{\text{sesgo por no ser el mismo puesto}}, \quad w_j = 1/\text{var}_j.$$

- Un vecino lejano se descuenta aunque esté perfectamente medido.
- El caso degenerado se resuelve solo: si todos los vecinos están lejos, el segundo término domina, el intervalo se dispara y la confianza cae, sin programar ninguna excepción.


## $\lambda$ no se elige: se estima por momentos

La diferencia observada entre dos celdas al cuadrado tiene dos partes, y una se conoce:  $(m_i - m_j)^2 - (1/W_i + 1/W_j)$  es lo que sobra tras descontar el ruido de medición de ambas. Eso se ajusta contra  $1 - s_j$  por mínimos cuadrados por el origen. Se estima **por escalón jerárquico**, porque varía un factor 18.

# El nivel jerárquico, como segundo eje de agrupación

- Dos personas con el mismo título no ocupan el mismo puesto. Lo que las separa es el nivel:  $\omega^2 = 0,2462$ .
- El recorrido salarial es de  $2,11\times$  entre el escalón más bajo —ayudante, auxiliar, operario— y el más alto —gerente, director.
- La escalera se estima **dentro de empresa y área**, así que no arrastra el efecto empleador ni la composición sectorial.
- El escalón sale de la propia etiqueta, por palabra de rango, y es lo que cierra el candado de la pasada semántica.

# La escalera de niveles




Salario relativo al escalón más bajo, estimado dentro de empresa y área.

# El tamaño de la empresa: corrige el centro, no la banda

- Segmentar el mercado por tamaño **no** estrecha la banda: la incertidumbre del centro sube más de lo que baja el ancho.
- Pero el centro está sesgado, y cada vez más cuanto más alto el escalón. Ahí entra, como **desplazamiento de la banda entera**, no como reestimación.
- Por escalón y no cargo a cargo: la selección automática cargo a cargo está medida y es ruido —el placebo eligió más cargos que la señal real.

*Segmentar para estrechar y segmentar para corregir el centro son dos preguntas distintas, y la respuesta no es la misma.*

# Sesgo de nivel por tamaño de empresa



A una empresa pequeña se le decía que su gerente general cobra un 56 % por debajo del mercado. Entre empresas de su tamaño, estaba bien pagado.

# Las reglas de medición se fijaron antes que el modelo

- Partición **por empresa**, nunca por fila: con partición aleatoria la empresa de evaluación aparece en ajuste y se acierta por la razón equivocada.
- Todo intervalo se **remuestrea por empresa**. Una persona se repite entre años y una empresa aporta cientos de personas: la fila no es la unidad independiente.
- Puntuación con pérdida *pinball* sobre la banda, en los cuantiles 0,25 y 0,75. Es una regla propia: se minimiza diciendo la verdad.
- El criterio de adopción se escribe **antes** de correr el experimento: qué resultado lo adoptaría y cuál lo rechazaría.
- El 20 % de evaluación final **no se ha tocado**, y se reserva para una sola pasada al congelar el método.

# El placebo es la pieza que decide

Cualquier reagrupación mejora la cobertura **por construcción**: se juntan celdas, hay más respaldo, las cifras se ven mejor. Eso no demuestra nada.

## El contraste

Se repite el experimento mandando **las mismas fusiones a destinos al azar**. Si el placebo mejora igual, la ganancia era mecánica.

| Fusión por errata | pinball         | IC 95 %                |
|-------------------|-----------------|------------------------|
| Regla real        | -0,00001        | $[-0,00004, +0,00002]$ |
| Placebo           | <b>+0,00130</b> | $[+0,00081, +0,00180]$ |

Cien veces peor. La distancia de edición está eligiendo bien el destino; no da igual dónde caiga la gente.

# Resultados medidos

|                                                            |                     |
|------------------------------------------------------------|---------------------|
| Efecto empleador sobre la varianza residual                | 81 %                |
| Techo de mejora por reagrupar                              | 12,1 %              |
| Títulos distintos en el catálogo                           | 65.181              |
| Puestos tras consolidar grafías                            | 50.420              |
| Cobertura directa, antes y después de consolidar           | 57,7 % → 64,1 %     |
| Títulos de una nómina nueva resueltos por analogía         | 35,9 %              |
| Varianza de nivel explicada por el escalón jerárquico      | $\omega^2 = 0,2462$ |
| Recorrido salarial entre el escalón más bajo y el más alto | 2,11×               |
| Error del centro en cargos altos, sin corregir por tamaño  | -56,0 %/+81,9 %     |
| Error del centro, corrigiendo                              | -12,1 %/+17,9 %     |