

BENCHMARKING SALARIAL CON ETIQUETAS DE PUESTO DELGADAS

Pablo Andrés Encalada

Maestría en Inteligencia Artificial, USFQ

EL PROBLEMA


EL PROBLEMA ES EL DENOMINADOR

- Un benchmark salarial estima cuantiles de la distribución de sueldos condicionada al puesto.
- El estimador es una mediana ponderada. La especificación del condicionante es el problema abierto.
- La práctica establecida impone una taxonomía cerrada y traslada el mapeo al cliente: manual, no reproducible entre codificadores, sin tasa de acuerdo publicada.
- Aquí el condicionante es la etiqueta declarada por el empleador, en texto libre.

EL CATÁLOGO ESTÁ EN RÉGIMEN DE ÁREA PEQUEÑA

- 65.181 títulos distintos, con mediana de 2 personas y 1 empresa por título.
- El 78 % de los títulos tiene una sola empresa detrás y cubre el 21 % de las personas.
- El 1 % con 30 o más empresas cubre el 46 %.
- La mayoría de las celdas no admite estimación directa: el problema es de estimación en áreas pequeñas, no de clasificación.

ESPESOR DEL CATÁLOGO DE CARGOS



Estudios actuariales de nómina, Ecuador 2024-2025, cruzados con el registro de la Superintendencia de Compañías.


EL ERROR IRREDUCIBLE ACOTA LA GANANCIA

Con $y = \log(\text{suelo}/\text{SBU})$, dentro de cada celda de cargo c :

$$y_{fi} = \mu_c + u_f + e_{fi}, \quad u_f \sim (0, \tau^2), \quad e_{fi} \sim (0, \sigma^2).$$

- Sobre el ajuste, $\tau = 0,2917$ y $\sigma = 0,1423$: el efecto empleador explica el **81 %** de la varianza residual.
- Contra ese suelo, el techo de mejora por reagrupar es del **12,1 %**, y del **13,2 %** sin la censura del salario básico.
- Es la referencia contra la que se reporta, no el cero.

DESCOMPOSICIÓN DEL ERROR DE PREDICCIÓN



En color, la fracción del error atribuible a agrupar mal. El resto lo genera el empleador y ningún estimador condicionado al puesto lo recupera.

EL MÉTODO

CUANTIL PONDERADO POR INVERSO DE VARIANZA

El voto de la empresa f es la mediana de sus n_f personas en la celda; la referencia, el cuantil ponderado al 50 % de los votos, con

$$w_f = \frac{1}{\tau_c^2 + \sigma_c^2/n_f}.$$

- Los regímenes límite son las dos convenciones del campo: $n_f \rightarrow \infty$ da un voto por empresa; $\tau_c^2 \rightarrow 0$, un voto por persona.
- El ratio de pesos lo acota la razón de varianzas,
 $w_{\max}/w_{\min} \leq 1 + \sigma_c^2/\tau_c^2 \approx 1,24$, no el tamaño relativo de las empresas.
- τ_c y σ_c se estiman por celda: el estimador no tiene hiperparámetros.

LA SIMILITUD NO ES EL PESO DEL VECINO

Ponderar por similitud $\times$ precisión invierte el orden correcto:

Vecinos de OPERADOR DE PARQUEADERO	Similitud	Peso
OPERADOR DE PARQUEADEROS	0,989	8 %
OPERADOR DE EXCAVADORA	0,825	46 %

Cada vecino j se trata como observación ruidosa del puesto objetivo:

$$\text{var}_j = 1/W_j + \lambda (1 - s_j), \quad w_j = 1/\text{var}_j.$$

λ se estima por escalón jerárquico, donde varía un factor 18. Si todos los vecinos están lejos, el segundo término domina $\leadsto$ el intervalo se ensancha y la confianza cae, sin regla ad hoc.

CONSOLIDACIÓN DE GRAFÍAS: TRES REGLAS SEPARABLES

1. **Semántica.** Enlace completo sobre el grafo de similitud, umbral 0,95.
El enlace simple percola: una componente de 1.758 títulos con ASISTENTE CONTABLE y AUXILIAR DE LIMPIEZA dentro.
2. **Ortográfica.** Indexado por variantes de borrado y absorción asimétrica: el grupo raro con ≤ 2 empresas entra en el común con ≥ 10 .
3. **Flexión de género**, conservando la diferencia medida antes de unir.

Cobertura directa: 57,7 % $\Rightarrow$ 64,1 %. El coseno no separa erratas de una letra: $s(\text{VENDEROR}, \text{VENDEDOR}) = 0,7177$.

PROTOCOLO, FIJADO ANTES DEL MODELO


- Partición **por empresa**: con partición por fila la empresa de evaluación aparece en ajuste y el acierto es espurio.
- Remuestreo **por empresa** en todo intervalo.
- Regla de puntuación propia: pérdida *pinball* en $q \in \{0,25; 0,75\}$ sobre la banda de empresas.
- Criterio de adopción declarado antes de correr cada experimento.
- **Placebo de permutación** en toda reagrupación: en D-031 permutar los destinos cuesta +0,00130 frente a -0,00001 de la regla real; en D-018 el placebo seleccionó 118 cargos contra 93 de la regla, y la descartó.
- El 20 % de evaluación final permanece intacto.

RESULTADOS MEDIDOS

LA HIPÓTESIS DE PARTIDA SE RECHAZÓ

- Hipótesis: la composición del pago —fijo, comisiones, extras— discrimina puestos dentro de una etiqueta ancha.
- Fuera de muestra, $R^2 = +0,0042$ contra placebo $-0,0002$: un 0,21 % del techo del 12 %. Se descarta.
- El eje con poder discriminante es el nivel jerárquico, $\omega^2 = 0,2462$, con un recorrido de $2,11\times$ entre el escalón más bajo y el más alto.
- El protocolo se construyó antes que el modelo y su primer resultado fue falsificar la premisa del proyecto.

EL EJE CON PODER DISCRIMINANTE



Escalera monótona dentro de empresa y área. El nivel jerárquico, no la composición del pago, es lo que separa puestos dentro de una etiqueta ancha.


HIPÓTESIS MEDIDAS Y NO ADOPTADAS

- Sector para estrechar la banda: pinball 0,1289 contra 0,1255 sin segmentar (D-022).
- Sector para corregir el centro: no se sostiene fuera de muestra (D-022).
- Escalera estimada con medianas: la media domina, +0,00069 (D-024).
- División o clase CIU en lugar de sección: degrada con la finura; la sección acierta un 9,2 % más (D-029).
- Contexto en el embedding: mejora el vecindario, pero el efecto sobre las bandas cruza cero (D-030).

SECTOR Y TAMAÑO: LA MISMA PREGUNTA, RESPUESTA OPUESTA

- **Sector.** Adoptado en D-014 y retirado en D-022. De la varianza de pago *entre* empresas para un mismo cargo, la división CIIU explica **6 puntos netos**: 0,389 en crudo contra 0,325 permutando. El resto es inflación mecánica por partición en grupos pequeños.
- **Tamaño.** No estrecha la banda —la incertidumbre del centro sube más de lo que baja el ancho— pero corrige un sesgo de nivel en los cargos altos.

SESGO DE NIVEL POR TAMAÑO DE EMPRESA



El rango de error del centro pasa de $-56,0\%$ / $+81,9\%$ a $-12,1\%$ / $+17,9\%$ al corregir por tamaño.

COBERTURA Y ALCANCE DE LO REPORTADO

Techo de cobertura de la etiqueta cruda	66,6 %
Cobertura directa, consolidada	64,1 %
Títulos de una nómina nueva fuera de la base	35,9 %
Empresas que aportan datos	6.722
Empresas resolubles por RUC	221.754

- El efecto empleador acota el alcance: lo estimado es el mercado, no la política salarial de una empresa concreta.
- Todo procede de particiones de validación dentro del ajuste. Es consistencia interna, no validación externa.

