

**Benchmarking salarial con etiquetas de
puesto delgadas:
cuánto error es reducible por elegir mejor
el grupo de comparación**

Pablo Andres Encalada

Maestria en Inteligencia Artificial — USFQ

22 de septiembre de 2026

Resumen

Un benchmark salarial responde a una pregunta simple: *cuánto paga el mercado por este puesto*. La dificultad no está en el cálculo sino en el denominador — qué puestos se consideran comparables. Este trabajo parte de un catálogo real de nóminas ecuatorianas donde la etiqueta de cargo es texto libre, y mide cuánto del error de un benchmark es reducible eligiendo mejor el grupo de comparación.

La contribución principal no es un algoritmo. Es una **medición del presupuesto disponible**: se descompone el error de predicción en la parte irreducible —la que genera el empleador— y la parte atribuible a agrupar mal, y se establece que el techo de mejora por agrupación es del orden del 12 %. Sobre ese techo se construye un estimador y se mide cuánto de él se recupera.

El trabajo incluye un resultado negativo en el centro: la hipótesis con la que arrancó el proyecto —que la composición del pago (fijo, comisiones, extras) discrimina puestos— se midió y quedó en un R^2 fuera de muestra de +0,0042 contra un placebo en -0,0002. El eje que sí paga resultó ser el *nivel jerárquico*, con $\omega^2 = 0,2462$ y un recorrido salarial de $2,11\times$ entre el escalón más bajo y el más alto. Ese giro, y el protocolo que lo hizo visible, son parte del aporte.

Índice general

Resumen	1
1. El problema	3
1.1. Qué es un benchmark salarial y por qué es difícil	3
1.2. El catálogo real	3
1.3. El límite que ningún método basado en el puesto puede cruzar	4
2. Un resultado negativo en el centro	6
2.1. La premisa con la que arrancó el proyecto	6
2.2. Por qué no se había medido	6
2.3. Lo que salió al medirlo	6
2.4. El eje que sí paga	7
2.5. La ceguera jerárquica de los embeddings	8
2.6. La reformulación	8
2.7. La lección de proceso	8
3. El método	9
3.1. Vista general	9
3.2. El estimador: pesos inverso-varianza	9
3.3. El vecindario semántico y por qué no se pesa por similitud	10
3.4. Consolidación de grafías	10
3.5. La banda	11
3.6. Corrección por tamaño de empresa	11
4. Protocolo de medición	12
4.1. Las reglas	12
4.2. Por qué el placebo es la pieza que decide	12
5. Lo que se midió y no entro	14
5.1. El caso del sector, que se adoptó y luego se retiró	14
6. Resultados	16
6.1. Cobertura	16
6.2. Estado del sistema	16
7. Limitaciones	17
8. Conclusiones	18

Capítulo 1

El problema

1.1. Qué es un benchmark salarial y por qué es difícil

Una empresa que quiere saber si paga bien necesita comparar el sueldo de cada persona contra lo que el mercado paga por *ese mismo puesto*. El cálculo es trivial: una mediana. La dificultad está enteramente en decidir qué observaciones entran en ella.

La industria resuelve esto con taxonomías duras: catálogos cerrados de puestos a los que el cliente mapea su nómina a mano. Ese mapeo es caro, es lento, y es donde se pierde la información — dos empresas mapean el mismo puesto a categorías distintas según quien haga el ejercicio.

La alternativa natural es usar la etiqueta que la empresa ya escribió. El problema es que esa etiqueta es texto libre.

1.2. El catálogo real

El universo de trabajo son estudios actuariales de nómina de empresas ecuatorianas, años 2024–2025, cruzados con el registro de la Superintendencia de Compañías. Tras limpieza el catálogo contiene **65.181 títulos distintos** de puesto.

La distribución de ese catálogo es el problema entero (figura 1.1):

Tabla 1.1: Espesor del catálogo de cargos

Títulos distintos	65.181
Mediana de personas por título	2
Mediana de empresas por título	1
Personas cubiertas por títulos con respaldo suficiente	66,6 %

La mitad de los títulos aparece en una sola empresa. Un tercio de las personas está en celdas de una o dos empresas. Calcular una mediana de mercado sobre eso no da un benchmark: da el sueldo de un vecino.




Figura 1.1: **Casi todos los puestos son delgados; casi toda la gente está en los gruesos.** El 78 % de los 50.420 puestos tiene una sola empresa detrás y entre todos cubren el 21 % de las personas. En el otro extremo, el 1 % de los puestos con 30 o más empresas cubre el 46 %. Esa asimetría es el problema: la cola larga no se arregla con más modelo, se arregla tomando fuerza prestada de un vecindario.

Y el catálogo está además sucio de una forma específica. El mismo puesto aparece tecleado de varias maneras —seis variantes de espaciado de **ASISTENTE ADMINISTRATIVO**, trece grafías de **VENDEDOR** incluyendo **VEENDEDOR**, **VENDEDRO** y **VEDEDOR**— y cada una es, para el sistema, un puesto distinto y delgado.

1.3. El límite que ningún método basado en el puesto puede cruzar

Antes de proponer nada conviene saber cuánto hay que ganar. Descomponiendo la varianza del logaritmo del sueldo normalizado por el salario básico unificado, dentro de cada celda de cargo:

$$y_{fi} = \mu_c + u_f + e_{fi}, \quad u_f \sim (0, \tau^2), \quad e_{fi} \sim (0, \sigma^2) \quad (1.1)$$

donde f indexa empresas e i personas dentro de la empresa. Medido sobre el conjunto de ajuste:

$$\tau = 0,2917 \quad \sigma = 0,1423$$

El efecto empleador τ es el doble que la dispersión dentro de la nómina. **La empresa explica el 81 % de lo que no se puede predecir desde el puesto.** Dos personas con el mismo cargo en empresas distintas cobran muy diferente, y eso no es ruido de medición: es la variable que de verdad gobierna el salario y que un benchmark por puesto no puede ver.

De ahí sale el presupuesto del trabajo (figura 1.2). Comparando la desviación del error real contra el suelo irreducible:

Tabla 1.2: Techo de mejora por agrupar mejor

Subconjunto	sd real	sd irreducible	Techo
Todo el ajuste	0,3700	0,3253	12,1 %
Lejos del piso del SBU ($y > 0,05$)	0,4322	0,3750	13,2 %

Una corrida anterior reportó 10,9 % sobre este mismo conjunto. La diferencia no es de alcance sino de agregación: allí el numerador promediaba desviaciones y el denominador varianzas, lo que subestima sd_{actual} en 0,3651. Con las dos agregadas igual, la cifra es 12,1 %.




Figura 1.2: **La franja en color es todo lo que una agrupación mejor puede recuperar.** El resto lo genera el empleador: $\tau = 0,29$ entre empresas frente a $\sigma = 0,14$ dentro de la nómina. Cuanto más lejos del piso del salario básico, más margen hay —abajo la distribución está comprimida contra el mínimo legal.

El techo es del orden del 12 %. Cualquier resultado debe leerse contra ese número, no contra cero. Un método que reduzca el error un 4 % está recuperando un tercio de todo lo que había disponible; uno que prometa un 40 % está midiendo mal.

Esta cifra es, en sí misma, una contribución: los trabajos previos comparan métodos entre sí sin establecer contra qué techo compiten.

Capítulo 2

Un resultado negativo en el centro

2.1. La premisa con la que arrancó el proyecto

El proyecto se diseñó sobre la hipótesis de que la **composición del pago** —que fracción del ingreso es sueldo fijo, comisión, horas extra— discrimina puestos que la etiqueta confunde. La intuición es razonable: un vendedor a comisión y un vendedor a sueldo hacen trabajos distintos aunque se llamen igual.

Sobre esa hipótesis se construyeron trece semanas de arquitectura: transformación ILR y aparato composicional, compuerta de masa fija, ponderación por probabilidad inversa, restricciones semi-supervisadas.

2.2. Por qué no se había medido

La composición estaba disponible en el **2,7 %** de las filas. La hipótesis se adoptó *por eliminación* —se descartaron sector, tamaño y antigüedad, y quedó ella— y como el dato no estaba, **era infalsable en el momento de adoptarla**.

Se recupero al 80 % arreglando el pipeline de ingesta (**D-001, D-008**), se midió que es un rasgo estable entre años, se midió cuanto de ella explica el empleador. Nunca se midió lo único que sostenía la tesis.

El hueco lo detectó una pregunta del director del proyecto: “*sacamos la composición pero en el EDA nunca analizamos nada de eso para ver si efectivamente es relevante*”.

2.3. Lo que salió al medirlo

La composición vale **0,21 % de reducción de desviación** sobre un techo del 12 %, con un placebo en cero. El rango jerárquico vale **59 veces más**.

La afirmación se enuncia estrecha, porque la medición es estrecha: *la composición no aporta información intra-empresa e intra-etiqueta sobre el sueldo base*. No “la composición no importa” — sobre compensación total es mecánicamente casi todo, y el diseño residualiza contra la empresa, que determina entre el 39 % y el 50 % de la propia composición.

Tabla 2.1: Poder discriminante de cada eje candidato, fuera de muestra

Eje	R^2 fuera de muestra	Reduce la sd
Placebo	−0,0002	—
Composición del pago	+0,0042	0,21 %
Antigüedad	+0,0114	0,57 %
Rango jerárquico (ω^2, dentro de área)	+0,2462	13,2 %

2.4. El eje que sí paga

El rango jerárquico da una escalera monótona de cinco escalones (figura 2.1) con un recorrido de $2,11\times$ **en salario** entre el nivel 1 y el nivel 5. Se obtiene de tres fuentes por orden de confianza:

1. **Lexico de rango** — la palabra de jerarquía en el propio título (AUXILIAR, ASISTENTE, JEFE, GERENTE). Cubre el 34,5 % de las personas, es gratis y es auditable.
2. **Catálogo MDT-2019-395**, niveles A–E oficiales definidos *por contenido de puesto*, no por sueldo.
3. Un clasificador para el resto, validado contra el 34,5 % donde la verdad se conoce.

Que el catálogo oficial defina los niveles por contenido y no por remuneración es lo que permite usarlo sin circularidad.




Figura 2.1: **El eje que sí paga.** Efecto de cada escalón sobre el salario, *dentro* de empresa y de área —o sea ya descontado el empleador, que es el factor dominante. La escalera es monótona y el recorrido entre el escalón más bajo y el más alto es de $2,11\times$. Comparese con la composición del pago, que en la misma medición vale un 0,21 % de reducción de desviación (tabla 2.1).

2.5. La ceguera jerárquica de los embeddings

El hallazgo que obliga a tratar el nivel aparte: el modelo de embeddings multilingüe codifica el *área* del puesto y no su *jerarquía*. Medido sobre pares del catálogo:

Pares que difieren solo en el rango	coseno 0,857
Pares que difieren solo en el área	coseno 0,764

El modelo considera *más parecidos* a dos puestos que difieren en jerarquía que a dos que difieren en área. Como el nivel vale un recorrido de $2,11\times$ en pago y el área no, agrupar por similitud semántica sin corregir fusiona puestos que cobran el doble. La jerarquía tiene que entrar por otra vía.

2.6. La reformulación

El enunciado de la tesis pasa a ser:

¿cuánto error de un benchmark salarial es reducible por elegir mejor el grupo de comparación, y qué precisión cuesta la taxonomía dura que vende la industria?

Con ese enunciado el resultado modesto deja de ser una decepción y pasa a ser una medición dentro de un presupuesto cuantificado. Y un modelo simple pasa a ser una virtud metodológica: uno complicado confundiría el techo con la capacidad del método.

2.7. La lección de proceso

Una hipótesis que no se puede falsar con los datos que hay no es un cimientito: es una apuesta. El correctivo no es desconfiar más, sino **ordenar el trabajo para que la premisa se mida primero**, aunque medirla exija arreglar el pipeline antes.

De esta entrada sale además una regla operativa del repositorio: *un número que no se puede reproducir no se defiende*. Toda medición que sostenga una afirmación vive en **research/experimentos/** con su script y su salida, commiteados el mismo día en que se mide.

Capítulo 3

El método

3.1. Vista general

El sistema construye una **base de referencia** una vez y la consulta muchas. Dado un título de puesto:

- si el título está en la base, se usa la referencia de su propia celda;
- si es nuevo, se embebe y se coloca entre los puestos que se le parecen.

Lo segundo no es un adorno: **el 35,9 % de las personas de una nómina nueva tiene un título que no está en la base**. Sin la rama de analogía la cobertura se queda en dos tercios.

El sistema *siempre* responde. La decisión es de producto: un cliente sin referencia no se queda quieto, se inventa un número. Pero como se responde siempre, la marca de confianza deja de ser decorativa — es lo único que separa “esto lo se” de “esto lo estoy suponiendo”.

3.2. El estimador: pesos inverso-varianza

Del modelo de la ecuación (1.1) se deriva todo lo demás sin hiperparámetros. El voto de cada empresa f en una celda es la mediana de sus personas, m_f , y se pondera por

$$w_f = \frac{1}{\tau^2 + \sigma^2/n_f} \quad (3.1)$$

La referencia es el cuantil ponderado al 50 % de los votos $\{m_f\}$ con esos pesos.

Este peso resuelve un debate de diseño que antes se zanjaba por criterio. Sus dos regímenes límite son las dos posturas:

Régimen	w_f tiende a	Equivale a
$n_f \rightarrow \infty$	$1/\tau^2$, igual para todas	una empresa, un voto
$\tau^2 \rightarrow 0$	n_f/σ^2	una persona, un voto

Y lo que resuelve el problema práctico: **el ratio máximo entre pesos está acotado por $1 + \sigma^2/\tau^2 \approx 1,24$** , no por el tamaño relativo de las empresas. Una

empresa de 3.000 personas no puede dominar la celda, y no hace falta descartar el voto de las pequeñas para conseguirlo.

Esta estructura ancla el trabajo en estimación en áreas pequeñas —tomar fuerza prestada de un vecindario— y no en la búsqueda de una variable que faltaba.

3.3. El vecindario semántico y por qué no se pesa por similitud

Para un título nuevo hay que combinar las celdas vecinas. La versión ingenua pesa cada vecino por *similitud* $\times$ *precision*. Medido sobre un caso real, eso rompe:

Tabla 3.1: Por qué la ponderación ingenua falla: OPERADOR DE PARQUEADERO

Vecino	Similitud	Peso ingenuo
OPERADOR DE PARQUEADEROS	0,989	8 %
OPERADOR DE EXCAVADORA	0,825	46 %

El sistema tenía la respuesta exacta delante y le hizo caso a una excavadora, porque la excavadora tenía más datos. La corrección es tratar cada vecino como una *observación ruidosa* del puesto objetivo, con varianza

$$\text{var}_j = \underbrace{1/W_j}_{\text{error de medición}} + \underbrace{\lambda(1 - s_j)}_{\text{castigo por no ser el mismo puesto}} \quad (3.2)$$

y pesar por $1/\text{var}_j$. Un vecino lejano se descuenta aunque este perfectamente medido.

λ **se estima de los datos, no se elige**: es cuánto difieren de verdad dos celdas por unidad de distancia semántica. Se estima por escalón jerárquico, porque varía un factor 18 entre ellos.

Esta formulación resuelve sola el caso degenerado. Para LOTERO el embedding no encuentra nada parecido y se agarra a la terminación *-ero*: LINIERO, BOTERO, LAMPERO, TESORERO, todos entre 0,748 y 0,784 de similitud. TESORERO paga 2,5 veces más. Con la varianza de la ecuación (3.2), si todos los vecinos están lejos el término $\lambda(1 - s_j)$ domina, el intervalo se dispara y la confianza cae a BAJA sin que haya que programar ninguna excepción.

3.4. Consolidación de grafías

Antes de estimar nada, las grafías del mismo puesto se juntan. Tres pasadas, en orden y por separado para que cada una sea auditable:

1. **Semántica**, por enlace completo sobre el grafo de similitud con umbral 0,95. El enlace *completo* y no el simple: medido, el enlace simple percola — produce un grupo de 1.758 títulos que contiene a la vez ASISTENTE CONTABLE y AUXILIAR DE LIMPIEZA, unidos por una cadena de saltos individualmente razonables.

2. **Por errata**, con indexado por variantes de borrado. Absorbe el grupo raro dentro del común exigiendo asimetría: el lado raro con ≤ 2 empresas, el común con ≥ 10 .
3. **Por grafía de genero**, que unifica ENFERMERA y ENFERMERO conservando y reportando la diferencia que había antes de unirlos.

La fusión sube la cobertura directa del **57,7 % al 64,1 %** sin costar precisión.

Un hallazgo lateral vale la pena: **el embedding no reconoce una errata de una letra**. VENDEROR contra VENDEDOR puntua 0,7177 frente a un umbral de fusión de 0,95. Las trece grafías de vendedor las unio la regla ortográfica, no el modelo semántico.

3.5. La banda

El entregable no es un número sino un intervalo, y la pregunta que responde es *que paga la mitad central de las empresas*. De ahí dos decisiones:

- **σ no entra en la banda de empresas**. El nivel de una empresa es $\mu_c + u_f$, con varianza τ_c^2 ; σ^2 separa a dos personas de la misma nómina y no mueve el nivel del empleador.
- **Con datos de sobra se usan los cuantiles empíricos** de los votos, no una normal. Describen la forma real, que va de un pico a una cola larga según el cargo.

Se entregan dos bandas: la de *empresas* para decisiones de política salarial, y la de *personas* —que si lleva σ — para situar a un individuo.

3.6. Corrección por tamaño de empresa

Segmentar el mercado por tamaño *no* estrecha la banda: medido, la incertidumbre del centro sube más de lo que baja el ancho. Pero el tamaño si corrige un **sesgo grande en el centro** de los cargos altos.

El caso que lo muestra: a una empresa pequeña se le decía que su gerente general cobra un 56 % por debajo del mercado, cuando entre sus pares de tamaño estaba bien. La corrección por desplazamiento lleva el rango de error de $-56,0 \%$ / $+81,9 \%$ a $-12,1 \%$ / $+17,9 \%$.

La lección metodológica es que *segmentar para estrechar* y *segmentar para corregir el centro* son dos preguntas distintas y la respuesta no es la misma.

Capítulo 4

Protocolo de medición

El instrumento se construyó antes que el modelo, deliberadamente (**D-002**). La contribución del trabajo es la medición, no el algoritmo, y una regla de medición torcida no se detecta midiendo: se detecta auditandola antes de usarla.

4.1. Las reglas

Partición por empresa, nunca por fila.

El empleador explica el 39 % del salario. Con partición aleatoria por fila, la empresa de test aparece en train y se acierta por la razón equivocada.

Todo intervalo se remuestrea por empresa.

La fila no es la unidad independiente: una persona recurre entre años y una empresa aporta cientos de personas. Tratarlas como independientes estrecha los intervalos sin derecho.

Puntuación propia.

La perdida *pinball* en $q = 0,25$ y $q = 0,75$ sobre la banda de empresas. Es estrictamente propia: se minimiza diciendo la verdad. El error absoluto es su caso degenerado.

Criterio escrito antes de mirar.

Cada experimento declara en su encabezado qué resultado lo adoptaría y cual lo rechazaria, antes de correr.

Placebo en todo cambio de agrupación.

Cualquier reagrupacion mejora la cobertura por construcción. El placebo —mismos grupos, destinos barajados— es lo único que distingue señal de mecánica.

El 20 % de test no se toca

hasta que el método este congelado en el pre-registro.

4.2. Por qué el placebo es la pieza que decide

Tres ejemplos de esta misma serie de experimentos:

- En la fusión por errata (**D-025**) el placebo *no* tuvo potencia, y la decisión se registro como “no validada, solo no contradicha”.

- Al ampliar esa regla (**D-031**) el placebo sí discriminó: mandar las mismas absorciones a destinos al azar cuesta +0,00130 de pinball frente a $-0,00001$ de la regla real, cien veces más. Eso es lo que demuestra que la distancia de edición elige bien el destino.
- En la segmentación selectiva por tamaño (**D-018**) el placebo **eligió más cargos que la seleccion real** — 118 contra 93 — lo que bastó para descartar el método.

Capítulo 5

Lo que se midió y no entro

Un catálogo de resultados negativos no es un apéndice: es lo que impide que el lector suponga que lo obvio no se probó.

Tabla 5.1: Hipótesis medidas y rechazadas

Hipótesis	Resultado	Ref.
La composición del pago discrimina puestos	$R^2 = +0,0042$ contra placebo $-0,0002$. Vale 0,21 % sobre un techo del 12 %	D-013
El sector estrecha la banda	pinball 0,1289 contra 0,1255 sin segmentar. Empeora	D-022
El sector corrige el centro	No se sostiene fuera de muestra. Se retira lo adoptado en D-014	D-022
La escalera de niveles debe estimarse con medianas	La mediana pierda contra la media: $+0,00069$, IC sobre cero. Hipótesis propia rechazada	D-024
Comparar contra el sector específico del cliente (division o clase CIU)	Peor cuanto más fino. Cambia el veredicto del 1,79 % de los cargos y en esos la sección acierta un 9,2 % más	D-029
Dar contexto al embedding mejora la representación	Mejora el vecindario (2/5 a 4/5 en pares sinónimo/rima) y <i>no</i> mueve las bandas: IC cruza el cero	D-030
Excluir al cliente de su propio mercado	Quitar una empresa mueve el centro un 1,2 % de la barra de error ya declarada. Corregirlo sería corregir ruido	D-027

5.1. El caso del sector, que se adoptó y luego se retiró

Merece detalle porque es el único eje que entro al modelo y después salió.

D-014 lo adoptó como “segundo eje del arquetipo” con una reducción del 13,2 % de desviación dentro de las etiquetas anchas y un placebo en 0,9 %. La condición que se le puso fue medirlo *fuera de muestra*. Al hacerlo (**D-022**) no se sostuvo, ni para la banda ni para el centro, y se retiró.

La razón de fondo apareció después, al descomponer la varianza: de la diferencia de pago *entre empresas* por un mismo cargo, la división CIIU explica **6 puntos netos** — 0,389 en crudo contra 0,325 barajando, o sea que casi todo es inflación mecánica de partir en grupos pequeños. Lo que una empresa paga por un contador depende de la empresa, no de si vende libros o repuestos.

El sector permanece en el producto como *lente* —el cliente ve contra que sector se le compara— pero no como mejora del modelo, y eso está escrito donde se implementa.

Capítulo 6

Resultados

6.1. Cobertura

Tabla 6.1: Cobertura del benchmark

Techo de cobertura de la etiqueta cruda	66,6 %
Cobertura directa antes de consolidar grafías	57,7 %
Cobertura directa después de consolidar	64,1 %
Personas de una nómina nueva con título desconocido	35,9 %

La rama de analogía es lo que convierte un sistema que cubre dos tercios en uno que responde siempre. El coste de responder siempre se paga en la marca de confianza, no en silencio.

6.2. Estado del sistema

Tabla 6.2: El artefacto

Títulos en la base	65.181
Puestos tras consolidar grafías	50.420
Empresas que aportan datos	6.722
Empresas resolubles por RUC (registro completo)	221.754
Decisiones de método registradas con evidencia	31
Pruebas automatizadas	381

Capítulo 7

Limitaciones

El techo es el techo.

El empleador explica el 81 % de lo que no se puede predecir desde el puesto. Este trabajo entrega el *mercado*, no la política salarial de una empresa concreta, y ningún método basado en la etiqueta de puesto puede cruzar esa frontera.

El conjunto de test sigue sin tocarse.

Todo lo reportado está medido sobre particiones de validación dentro del conjunto de ajuste. Es correcto por diseño —el test se toca una vez, después del pre-registro— pero significa que lo que hay es consistencia interna, no generalización demostrada.

Dos años de datos.

El universo es 2024–2025, los únicos años con plantilla completa. No hay serie temporal suficiente para separar tendencia de nivel.

El 30 % de las empresas no cruza con el registro.

De las 6.722 que aportan datos, 1.987 no presentan balances en la Superintendencia —probablemente sector público, fundaciones y personas naturales— y para ellas no hay sector ni tamaño.

El modelo de embeddings es un límite blando.

Con títulos de una a tres palabras en español no separa el sinónimo de la rima: DENTISTA puntúa 0,752 con TELEFONISTA y 0,763 con ODONTOLOGA. Once milésimas entre una terminación compartida y un sinónimo. Medido (**D-030**), esto degrada el buscador de puestos y *no* degrada las bandas, porque la banda depende de cuántas empresas respaldan el cargo mucho más que de cuál es su vecino más cercano.

Capítulo 8

Conclusiones

1. **El presupuesto está cuantificado.** El techo de mejora por agrupar mejor es del orden del 12 %, y el 81 % de lo irreducible lo genera el empleador. Cualquier afirmación sobre benchmarking salarial debería declarar contra qué techo compite.
2. **La premisa central del proyecto era falsa y se midió.** La composición del pago vale 0,21 % de reducción de desviación contra un placebo en cero. El eje que paga es el nivel jerárquico, con $\omega^2 = 0,2462$ y un recorrido de $2,11\times$.
3. **El problema es de estimación en áreas pequeñas,** no de encontrar la variable que faltaba. La etiqueta de cargo no está semánticamente rota: está estadísticamente delgada, con mediana de dos personas y una empresa por título.
4. **Los embeddings son ciegos a la jerarquía** y eso no es un detalle: el eje al que son ciegos vale $2,11\times$ en pago y el que sí capturan no. Agrupar por similitud semántica sin corregir fusiona puestos que cobran el doble.
5. **El protocolo produjo más hallazgos que el modelo.** De las 31 decisiones registradas, siete son resultados negativos que cerraron líneas de trabajo, y tres de ellas contradijeron hipótesis propias (**D-013**, **D-022**, **D-024**). El placebo y el criterio escrito antes de mirar son lo que hizo esos hallazgos visibles.

Bibliografía

- [1] Fay, R. E. y Herriot, R. A. (1979). *Estimates of income for small places: an application of James–Stein procedures to census data*. Journal of the American Statistical Association, 74(366), 269–277. [VERIFICAR paginación]
- [2] Rao, J. N. K. y Molina, I. (2015). *Small Area Estimation*, 2.^a ed. Wiley.
- [3] Gneiting, T. y Raftery, A. E. (2007). *Strictly proper scoring rules, prediction, and estimation*. Journal of the American Statistical Association, 102(477), 359–378. [VERIFICAR paginación]
- [4] Zaoui, A., Denis, C. y Hebiri, M. *Regression with reject option and application to kNN* . [VERIFICAR año y venue]
- [5] Ministerio del Trabajo del Ecuador (2019). *Acuerdo Ministerial MDT-2019-395*: escala de niveles ocupacionales.
- [6] Ministerio del Trabajo del Ecuador (2025). *Acuerdo Ministerial MDT-2025-195*: salario básico unificado 2026. Registro Oficial, Suplemento 187, 18 de diciembre de 2025.